



UNIVERSIDAD
NACIONAL
DE LA PLATA

Minería de Datos y Aprendizaje Automático

Clase 4
Métricas de evaluación - Ensembles

2026

Temario

1. Métricas de evaluación
2. Ensembles
3. Bagging
4. Boosting
5. Stacking

01

Métricas de evaluación



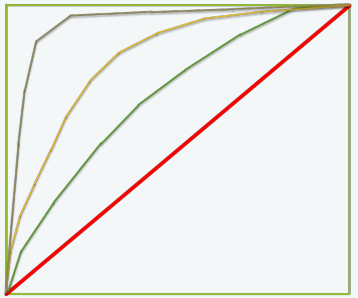
Métricas de evaluación

		Clase predicha				
		Clase A	Clase B	Clase C	Clase D	Clase E
Clase real	Clase A	TN	FP	TN	TN	TN
	Clase B (positivo)	FN	TP	FN	FN	FN
	Clase C	TN	FP	TN	TN	TN
	Clase D	TN	FP	TN	TN	TN
	Clase E	TN	FP	TN	TN	TN

Métricas en problemas de clasificación:

- Matriz de confusión
- Exactitud (Accuracy)
- Precisión (Precision)
- Exhaustividad (Recall)
- F-score
- Especificidad (Specificity)
- Tasa de falsos negativos (False negative rate)
- Tasa de falsos positivos (False positive rate)
- Curvas ROC (Receiver Operating Characteristic)
- Curvas Precision-Recall
- Área bajo la curva
- *Algunas más…*

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo (P)	TP Verdaderos positivos	FN Falsos negativos
	Negativo (N)	FP Falsos positivos	TN Verdaderos negativos



Matriz de confusión

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo (P)	TP Verdaderos positivos	FN Falsos negativos
	Negativo (N)	FP Falsos positivos	TN Verdaderos negativos

En problemas de clasificación binario, la matriz de confusión nos muestra para cada clase, los aciertos y fallos de las predicciones.
Por lo general, en estos problemas se trabaja con una clase positiva y otra negativa.
Ej: ausencia o presencia de una enfermedad.

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo	154	0
	Negativo	0	168

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo	109	45
	Negativo	16	152

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo	79	75
	Negativo	86	82

Exactitud (Accuracy)

¿Qué tanto acierta el modelo?

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo (P)	TP	FN
	Negativo (N)	FP	TN

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo	20	5
	Negativo	21	1002

$$\frac{(TP+TN)}{(TP+FN+FP+TN)}$$

Accuracy 97,52%
¿Nos sirve este modelo?

Precisión (Precision)

Cuando predice la clase positivo ¿Qué tan seguro está?

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo (P)	TP	FN
	Negativo (N)	FP	TN

$$\frac{TP}{(TP+FP)}$$

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo	20	5
	Negativo	21	1002

Precision 48,78%

Exhaustividad (Recall)

¿Cuánto acierta de la clase positivo?

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo (P)	TP	FN
	Negativo (N)	FP	TN

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo	20	5
	Negativo	21	1002

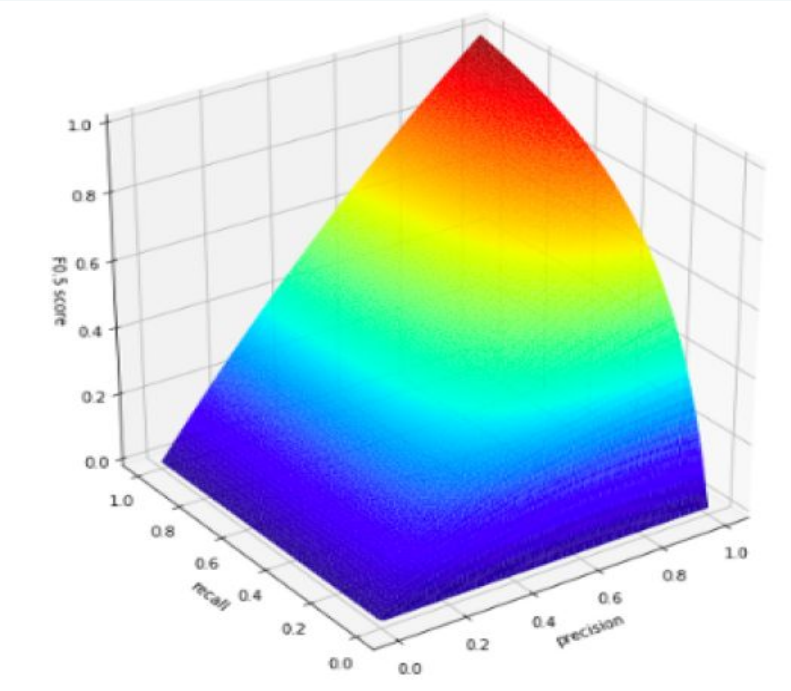
$$\frac{TP}{(TP+FN)}$$

Recall 80,00%

También llamada sensibilidad (sensitivity)

Medida F (F-score)

Media ponderada entre precisión y exhaustividad



		Clase predicha	
		Positivo	Negativo
Clase real	Positivo	20	5
	Negativo	21	1002

F-Score 60,61%

$$2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

Especificidad (Specificity)

¿Cuánto acierta de la clase negativo?

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo (P)	TP	FN
	Negativo (N)	FP	TN

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo	20	5
	Negativo	21	1002

$$\frac{TN}{(FP+TN)}$$

Specificity 97,94%

Tasa de falsos negativos (False negative rate)

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo (P)	TP	FN
	Negativo (N)	FP	TN

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo	20	5
	Negativo	21	1002

$$\frac{FN}{(TP+FN)}$$

FNR 20,00%

¿En qué proporción dice el modelo que una muestra es negativa, cuando no lo es?

Tasa de falsos positivos (False positive rate)

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo (P)	TP	FN
	Negativo (N)	FP	TN

$$\frac{FP}{(FP+TN)}$$

		Clase predicha	
		Positivo	Negativo
Clase real	Positivo	20	5
	Negativo	21	1002

FPR 02,05%

¿En qué proporción dice el modelo que una muestra es positiva, cuando no lo es?

Exactitud (Accuracy)

Problemas multiclase

		Clase predicha				
		Clase A	Clase B	Clase C	Clase D	Clase E
Clase real	Clase A	AA				
	Clase B		BB			
	Clase C			CC		
	Clase D				DD	
	Clase E					EE

$$\frac{(AA+BB+CC+DD+EE)}{\textit{total de muestras}}$$

Métricas restantes

Problemas multiclase

		Clase predicha				
		Clase A	Clase B	Clase C	Clase D	Clase E
Clase real	Clase A	TN	FP	TN	TN	TN
	Clase B	FN	TP	FN	FN	FN
	Clase C	TN	FP	TN	TN	TN
	Clase D	TN	FP	TN	TN	TN
	Clase E	TN	FP	TN	TN	TN



		Clase predicha	
		Clase B	Clase ACDE
Clase real	Clase B (positivo)	TP	Σ FN
	Clase ACDE (negativo)	Σ FP	Σ TN

Cálculo de métricas

```
from sklearn import metrics

cm = metrics.confusion_matrix(T_test, T_pred)
print(cm)
metrics.ConfusionMatrixDisplay(confusion_matrix=cm).plot();
# https://scikit-learn.org/stable/modules/generated/sklearn.metrics.confusion_matrix.html

print(metrics.precision_score(T_test, T_pred))
# https://scikit-learn.org/stable/modules/generated/sklearn.metrics.precision_score.html

print(metrics.recall_score(T_test, T_pred))
# https://scikit-learn.org/stable/modules/generated/sklearn.metrics.recall_score.html

print(metrics.f1_score(T_test, T_pred))
# https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html

p,r,f,s = metrics.precision_recall_fscore_support(T_test, T_pred)
# https://scikit-learn.org/stable/modules/generated/sklearn.metrics.precision_recall_fscore_support.html
```

Curvas ROC

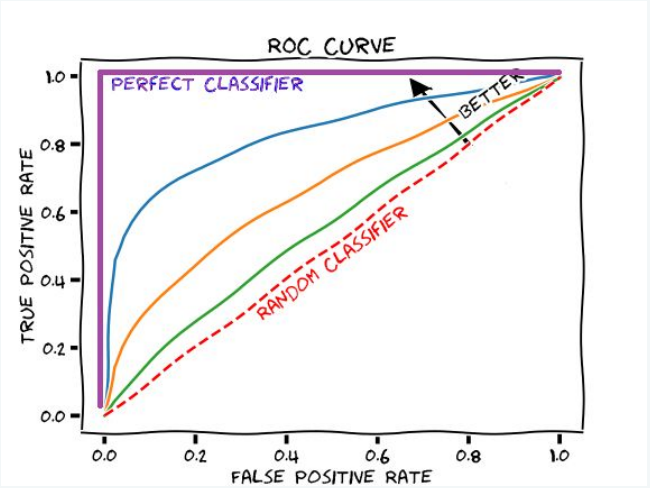
Una curva ROC (Receiver Operating Characteristic (Característica Operativa del Receptor)) es una representación gráfica del rendimiento de un modelo de clasificación binaria para todos los posibles umbrales de clasificación.

Permite visualizar la sensibilidad versus la especificidad de un modelo.

Sensibilidad → TPR = TP / (TP+FN)

1 - Especificidad → FPR = FP / (FP+TN) =

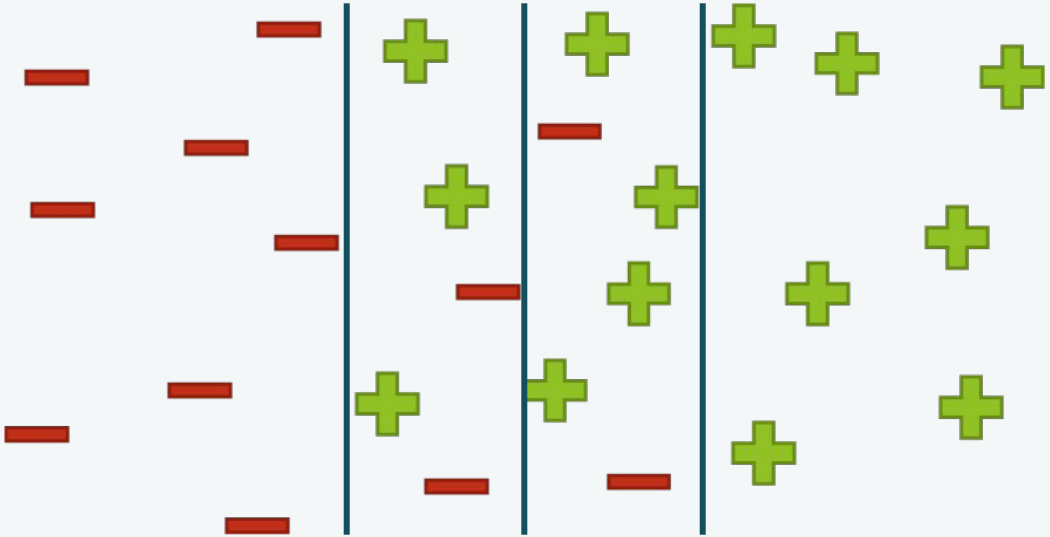
= 1 - TN / (FP+TN)

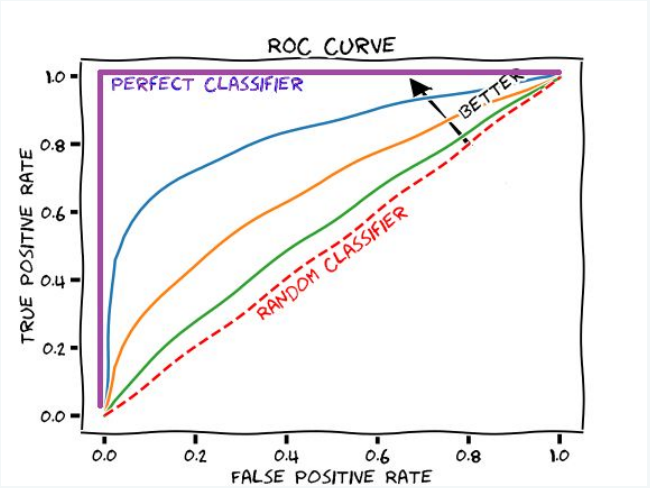


TP	FN
FP	TN

Curvas ROC

Muchos algoritmos trabajan con un umbral de decisión. Según donde se encuentre ese umbral, el error puede mejorar la TPR, empeorando la FPR; o viceversa.





TPR = 11 / 14 = 0.78
FPR = 1 – 10 / 12 = 0.17

TPR = 7 / 14 = 0.5
FPR = 1 – 12 / 12 = 0

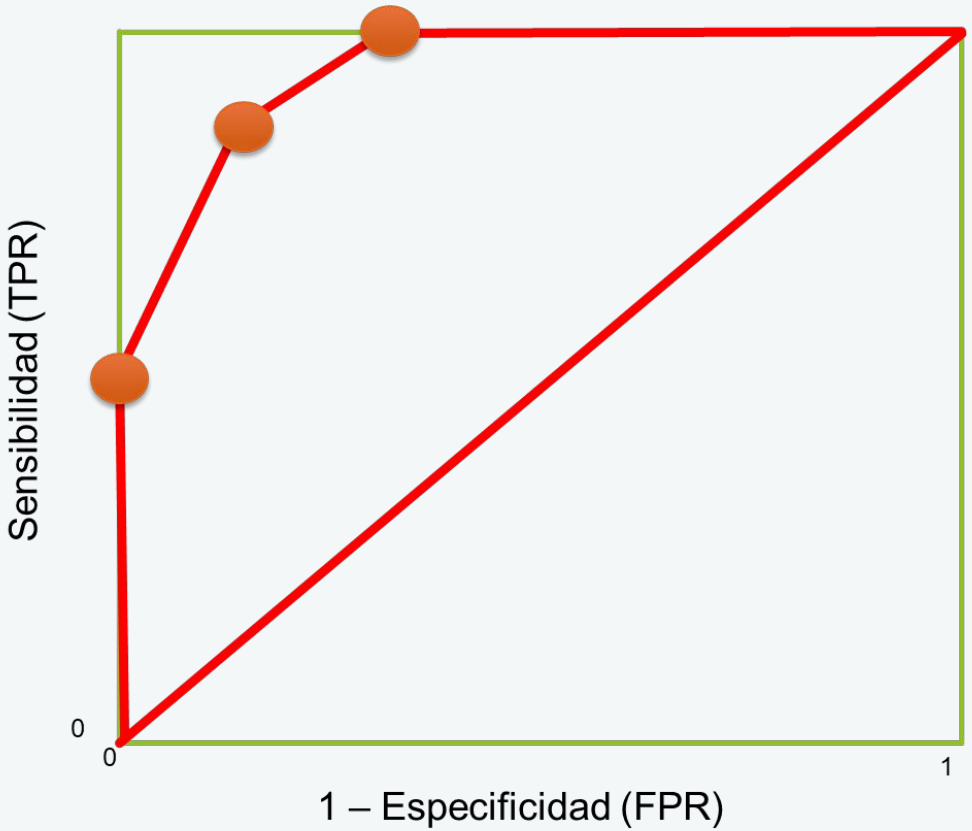
TPR = 14 / 14 = 1
FPR = 1 – 8 / 12 = 0.33

Curvas ROC

TPR = 11 / 14 = 0.78
FPR = 1 – 10 / 12 = 0.17

TPR = 7 / 14 = 0.5
FPR = 1 – 12 / 12 = 0

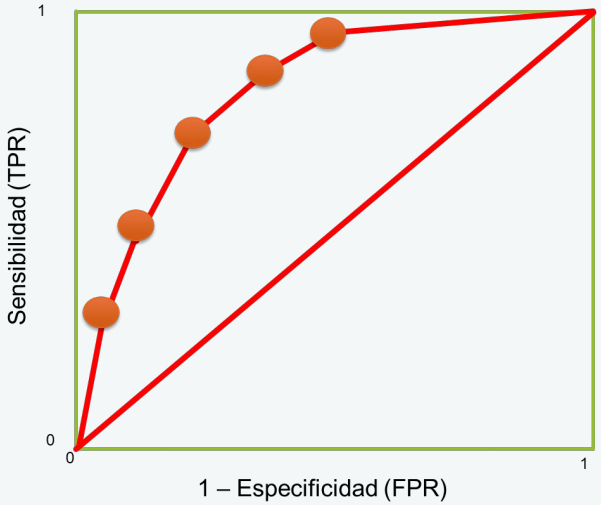
TPR = 14 / 14 = 1
FPR = 1 – 8 / 12 = 0.33



Curvas ROC

Si el algoritmo da una respuesta probabilística, también se puede hacer el mismo ejercicio, pero modificando el umbral de redondeo.

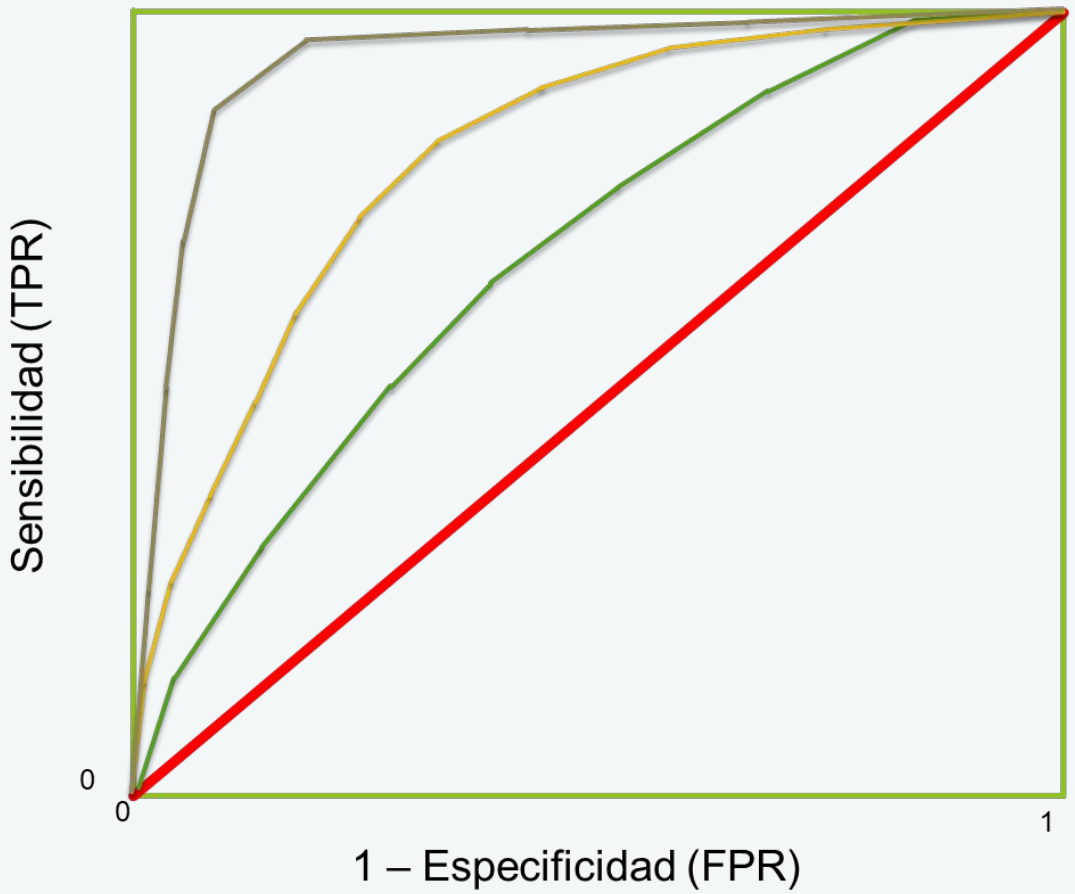
Target	Prob. clase 1	Umbral 0.2	Umbral 0.4	Umbral 0.5	Umbral 0.7	Umbral 0.85
1	0.8	1	1	1	1	0
0	0.3	1	0	0	0	0
1	0.6	1	1	1	0	0
0	0.2	1	0	0	0	0
1	0.7	1	1	1	1	0
1	0.9	1	1	1	1	1
0	0.4	1	1	0	0	0



Curvas ROC

Cuanto más cercana esté del (0,1) mejor será el modelo.

La línea roja marca la eficacia del azar.



AUC ROC

El área bajo la curva ROC (AUC ROC) nos da un indicador del modelo.

Es utilizado para comparar poder pronóstico entre diferentes modelos.



Curvas ROC

```
from sklearn.metrics import roc_curve, auc

dt = DecisionTreeClassifier(max_depth = 4)
model = dt.fit(X_train, T_train)

# Para las curvas ROC necesitamos las probabilidades devueltas para cada muestra
probs = model.predict_proba(X_test)

# Calcula la curva ROC
fpr, tpr, thresholds = roc_curve(T_test, probs)

# Calcula el área bajo la curva
roc_auc = auc(fpr, tpr)

# https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_curve.html
```

Curvas ROC

```
import matplotlib.pyplot as plt

# Para graficar la curva ROC
probs = model.predict_proba(X_test)

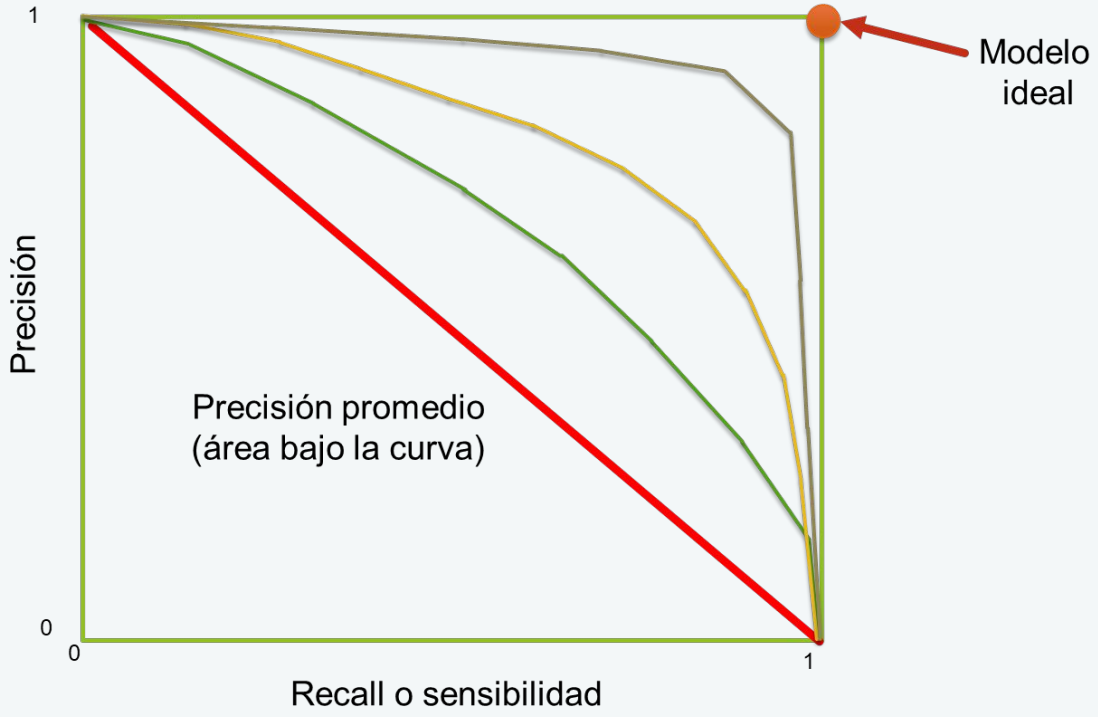
plt.figure()
plt.plot(fpr, tpr, label='ROC curve (area = %0.2f)' % roc_auc)
plt.plot([0, 1], [0, 1], 'k--', label='No Skill')
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('ROC Curve for Breast Cancer Classification')
plt.legend()
plt.show()
```

Curvas Precision-Recall

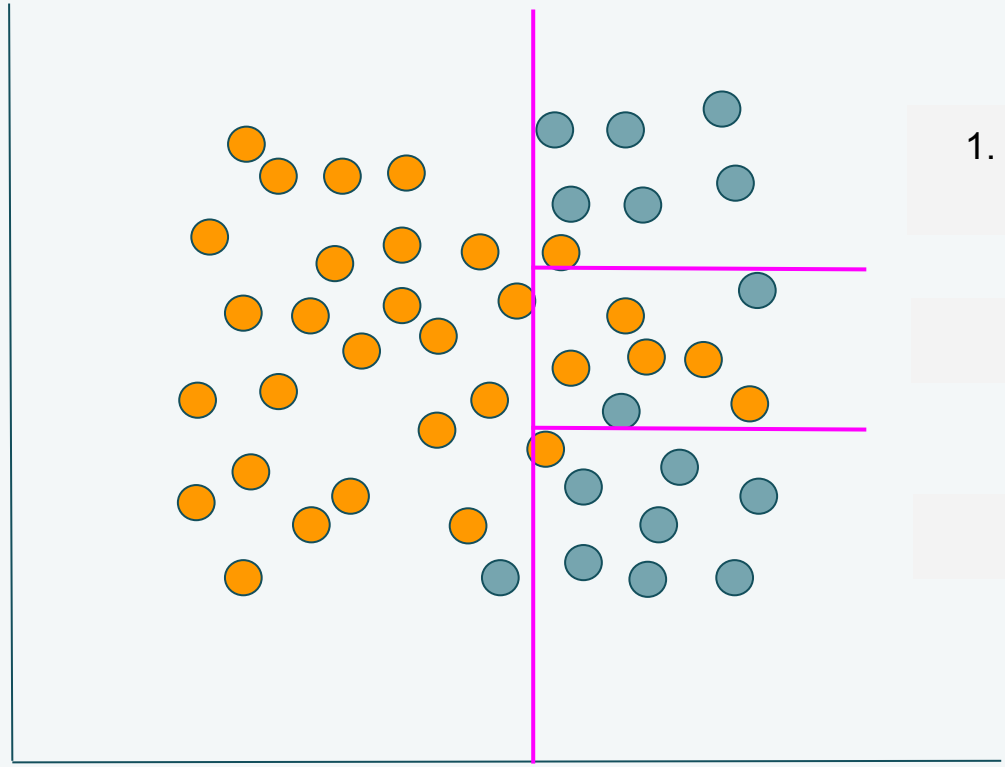
Otra curva que suele utilizarse es la curva PR (Precision-Recall).

Se construye de la misma manera que la curva ROC, pero utilizando las métricas precision y recall.

Dadas las características de las métricas, el modelo ideal está en (1,1).

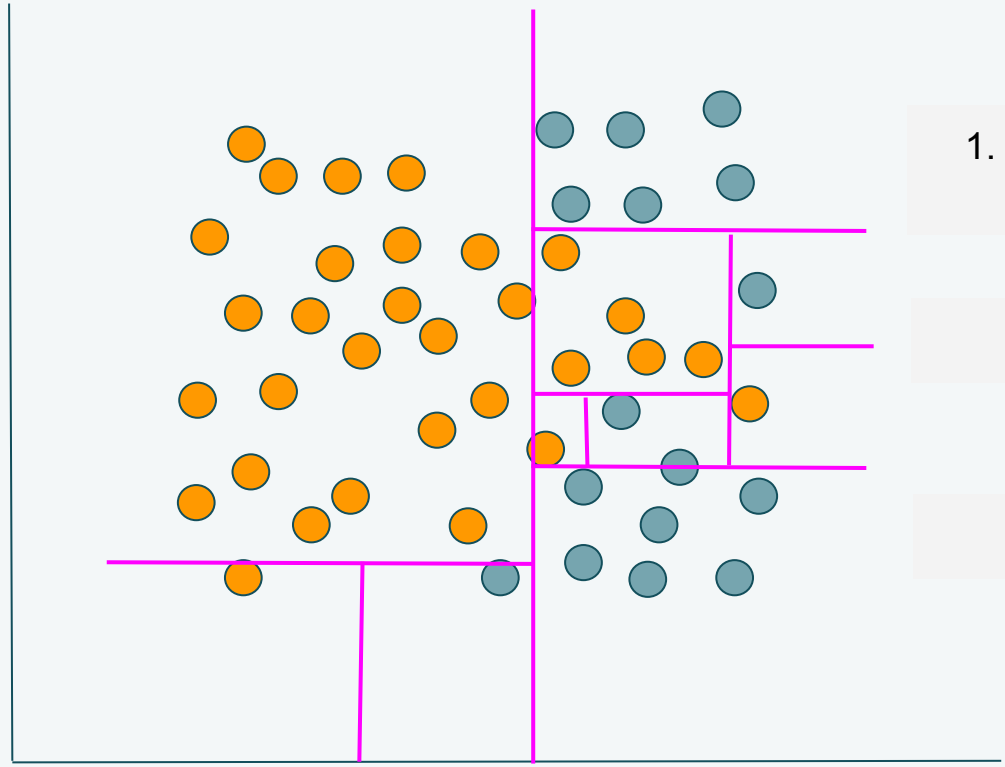


Evaluando al modelo



1. Separamos en train-test (random_state = 13)
2. Entrenamos
3. Testeamos

Evaluando al modelo



1. Separamos en train-test (random_state = 27)
2. Entrenamos
3. Testeamos

Rigor estadístico

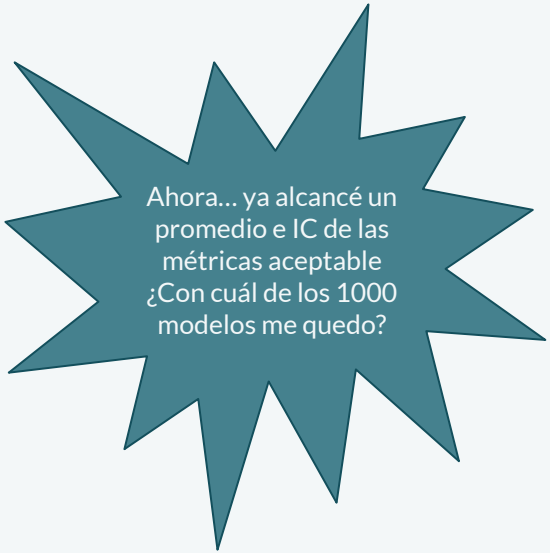
Bootstraping

1. Generar **B** nuevos conjuntos de prueba (normalmente 1000) haciendo muestreo con reemplazo del conjunto original.
   Cada nuevo conjunto tendrá el mismo tamaño **N** pero algunos datos se repetirán y otros no aparecerán.
2. Evaluar la/s métrica/s a utilizar en cada uno de los **B** ensayos, obteniendo así 1000 valores diferentes.
3. Calcular el promedio de cada métrica y su intervalo de confianza.

En estadística, la ley de los grandes números menciona un mínimo de 30 ensayos distintos, para asegurar que el promedio empiece a "estabilizarse" en su valor final. Aunque siempre dependerá de las características del dataset a analizar.

Intervalo de confianza del 95%

$$X \pm 1.96 \frac{\sigma}{\sqrt{n}}$$



Actividades

1. Utilice la base de datos “glass”, separando en 90-10.

   Calcule e imprima la matriz de confusión.

   Calcule e imprima accuracy, precision, recall, f-score y AUC-ROC.

   Repita los cálculos 10 veces, cambiando el random_state en el split. Calcule el promedio e IC_95% de cada métrica.