



UNIVERSIDAD
NACIONAL
DE LA PLATA

Minería de Datos y Aprendizaje Automático

Clase 5

Balance de clases - Selección de características - Sistemas de recomendación

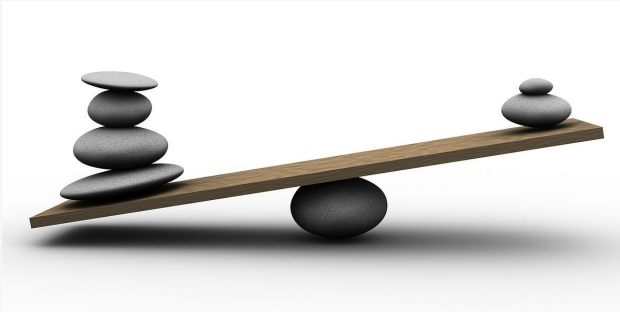
2026

Temario

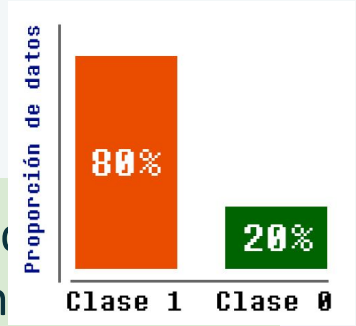
1. Técnicas de balance de clases
2. Selección de características
3. Sistemas de recomendación

01

Técnicas de balance de clases



Desbalance de clases



Se denomina “desbalance de clases” o “conjunto d
desbalanceado” a aquel dataset que presenta un
diferencia entre el número de muestras pertenecientes a distintas clases.

En problemas de clasificación binaria:

- Se denomina “clase mayoritaria” a aquella clase que tiene la mayor proporción de las muestras.
- Se denomina “clase minoritaria” a aquella clase que posee la menor proporción de las muestras. Por lo general, es la clase más importante. Ej: Detección de enfermedades, riesgos crediticios, eventos climáticos, etc.

Desbalance de clases

El problema de trabajar con datasets desbalanceados es que los modelos terminan aprendiendo más de la clase mayoritaria, ya que intentan minimizar el error global.

Solución: balancear el dataset

- Undersampling
- Oversampling
- Ponderación de clases

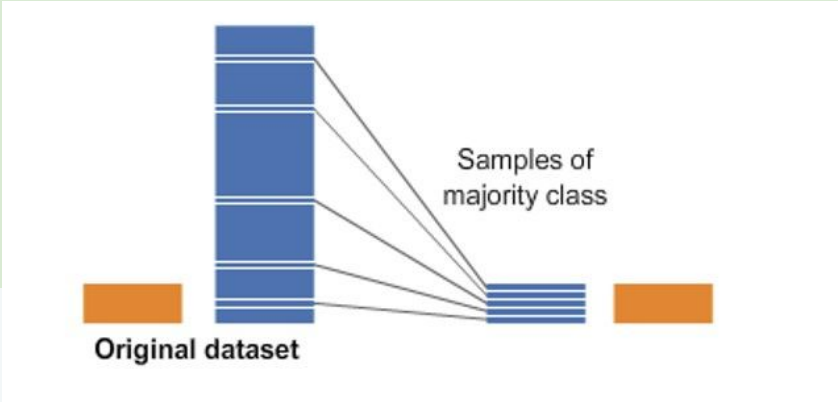
		Clase predicha	
		Positivo	Negativo
Clase real	Positivo	0	20
	Negativo	0	25000

Submuestreo (undersampling)

La técnica de submuestreo consiste en balancear la distribución de los datos reduciendo el número de muestras de la clase mayoritaria y dejando intacta la cantidad de la clase minoritaria.

El problema de la técnica de submuestreo es que quedan muchas muestras fuera del dataset de entrenamiento.

- Random Under Sampling
- Tomek Links
- NearMiss
- KNNs



Submuestreo (undersampling)

El submuestreo aleatorio (Random UnderSampling, RUS) consiste en eliminar muestras aleatorias de la clase mayoritaria.

La desventaja de este método es que, por azar, puede ignorar información potencialmente útil.

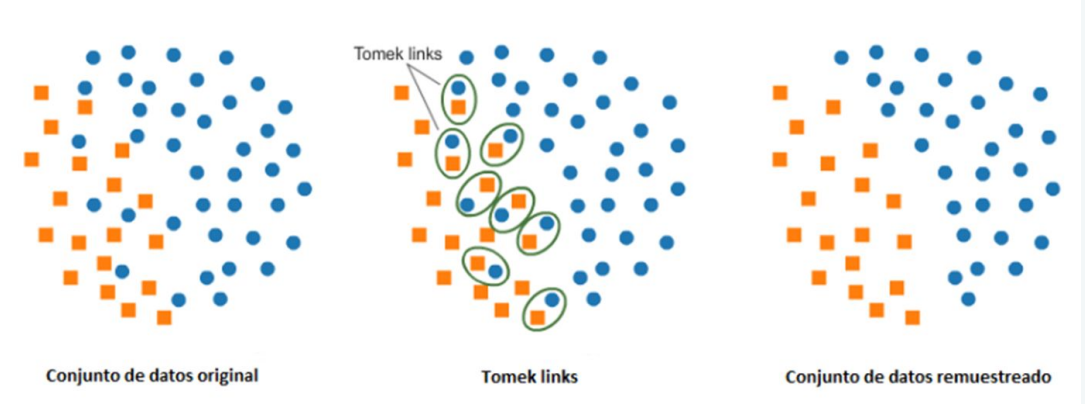


Submuestreo (undersampling)

La técnica “Tomek links” consiste en eliminar sólo muestras de la clase mayoritaria que sean redundantes o que estén muy próximas a muestras de la clase minoritaria.

Dos muestras *x*, *y* de diferentes clases son un “Tomek link” si para cualquier muestra *z* se cumple: $d(x,y) < d(x,z)$ y $d(x,y) < d(y,z)$, donde *d* es la distan
las muestras.

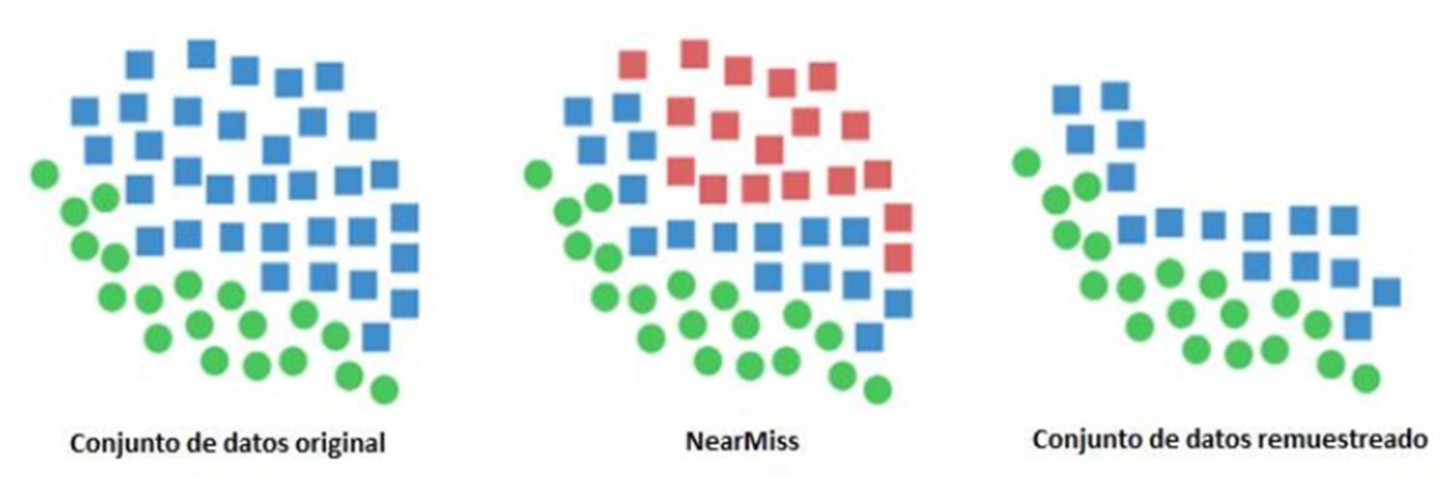
Podría introdu
favor de la clase minoritaria.



Submuestreo (undersampling)

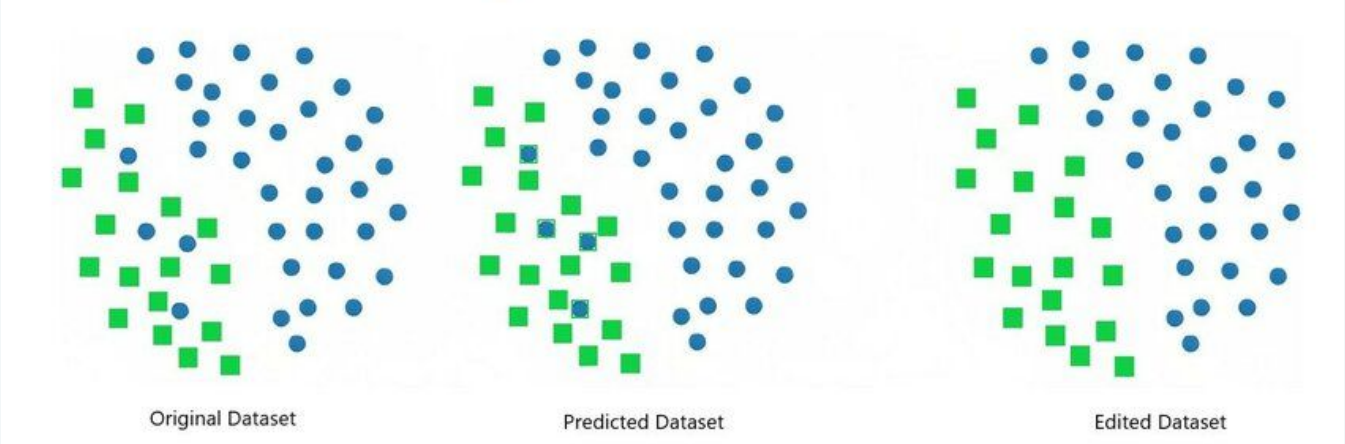
La técnica “NearMiss” selecciona un número dado de muestras de la clase mayoritaria más próximas a cada muestra de la clase minoritaria.

Podría introducir sesgos en problemas multiclase y eliminar zonas “confiables” de alguna clase.



Edited nearest neighbours

Basado en el resultado de entrenar un algoritmo K-NN, esta técnica analiza los K vecinos más cercanos a cada muestra de la clase minoritaria, eliminando aquellas donde sus vecinos (la mayoría o todos según su configuración) pertenecen a clases distintas.



Undersampling

```
from imblearn.under_sampling import RandomUnderSampler
from imblearn.under_sampling import TomekLinks
from imblearn.under_sampling import NearMiss
from imblearn.under_sampling import EditedNearestNeighbours

rus = RandomUnderSampler(random_state=11)
X_resampled, T_resampled = rus.fit_resample(X, T)

tl = TomekLinks()
X_resampled, T_resampled = tl.fit_resample(X, T)

nms = NearMiss(version=1)
X_resampled, T_resampled = nms.fit_resample(X, T)

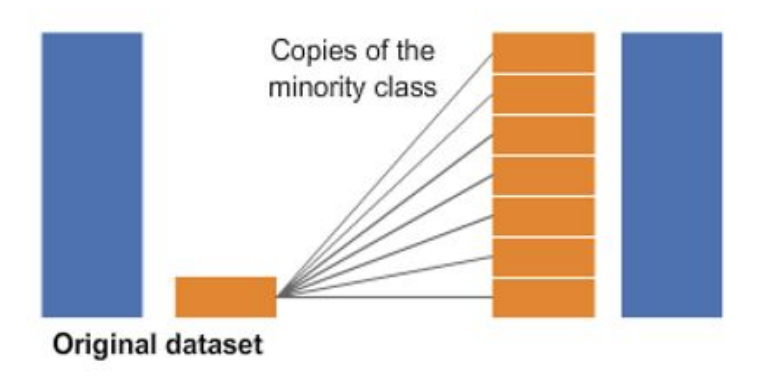
enn = EditedNearestNeighbours(kind_sel="all", n_neighbors=5)
X_resampled, T_resampled = enn.fit_resample(X, T)
# https://imbalanced-learn.org/stable/under_sampling.html
```

Sobremuestreo (oversampling)

El sobremuestreo consiste en balancear la distribución de los datos incrementando el número de muestras de la clase minoritaria y dejando intacta la cantidad de la clase mayoritaria.

Añadir muestras a la clase minoritaria para balancear el conjunto de datos causa que el dataset de entrenamiento crezca en volumen.

- Random Over sampling
- SMOTE
- ADASYN

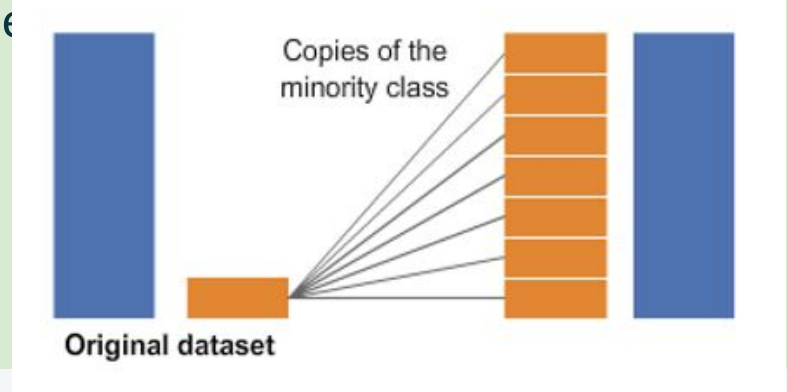


Sobremuestreo (oversampling)

El Sobremuestreo Aleatorio (Random OverSampling, ROS) consiste en equilibrar el conjunto de datos replicando las muestras de la clase minoritaria.

ROS aumenta la proporción de solapamiento entre instancias de diferentes clases, debido a la duplicación de datos, ya que la replicación de las muestras hace
entre los atributos sea mayor.

ROS es muy
conjuntos de datos
índice de desequilibrio.

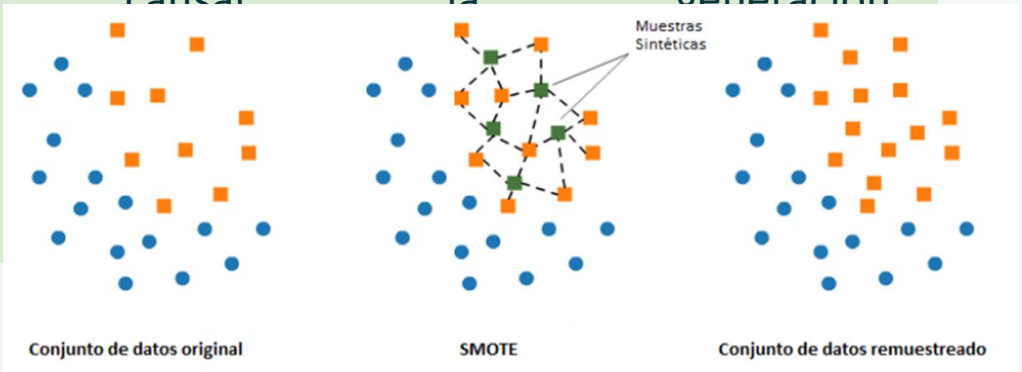


Sobremuestreo (oversampling)

El Sobremuestreo Sintético (Synthetic Minority Oversampling Technique, SMOTE) consiste en generar muestras sintéticas. SMOTE selecciona una muestra de la clase minoritaria y de entre sus vecinos más cercanos selecciona uno y crea una nueva muestra entre ambos.

Presenta un problema conocido como “generalización excesiva”, esto es, al generar nuevas muestras no tiene en cuenta las muestras vecinas de otras clases, lo que podría causar la generación de muestras “ruidosas”.

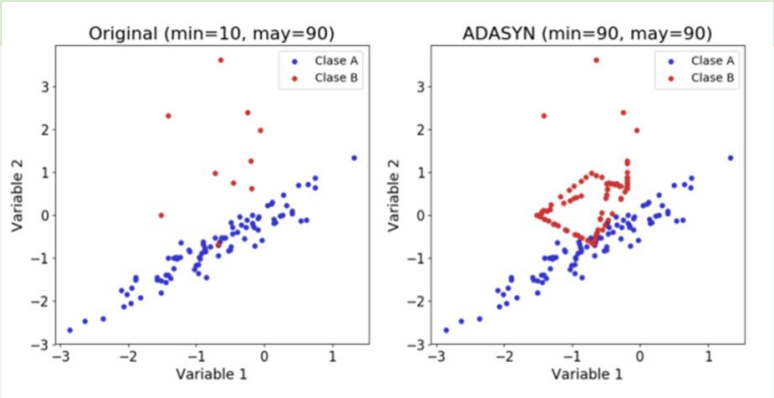
Existen muchas algoritmo.



Sobremuestreo (oversampling)

El Muestreo Sintético Adaptativo (Adaptive Synthetic Sampling Approach for Imbalanced Learning, ADASYN) es una extensión de SMOTE. ADASYN consiste en generar más muestras sintéticas en las zonas fronterizas para “aliviar” el problema del solape entre clases.

las nuevas muestras son generadas a partir de las muestras fronterizas, a través de una distribución de densidad. Esto causa que se vaya modificando el límite de decisión.



Oversampling

```
from imblearn.over_sampling import RandomOverSampler
from imblearn.over_sampling import SMOTE
from imblearn.over_sampling import ADASYN

ros = RandomOverSampler(random_state=0)
X_resampled, T_resampled = ros.fit_resample(X, T)

smt = SMOTE()
X_resampled, T_resampled = smt.fit_resample(X, T)

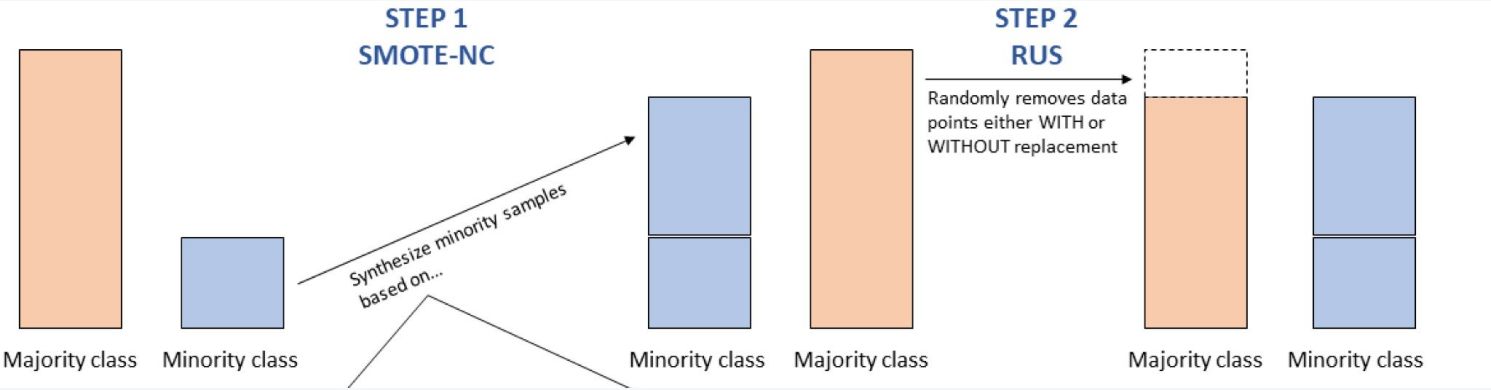
ada = ADASYN(sampling_strategy='minority')
X_resampled, T_resampled = ada.fit_resample(X, T)

# https://imbalanced-learn.org/stable/over_sampling.html
```

Escenarios híbridos

Cuando el desbalance es muy marcado, se puede analizar la posibilidad de usar under y oversampling sobre el dataset de datos.

La clase minoritaria se aumenta mediante oversampling, al mismo tiempo que la clase mayoritaria se reduce utilizando subsampling.



Escenarios híbridos

```
from imblearn.combine import SMOTEENN
from imblearn.combine import SMOTETomek

smote_enn = SMOTEENN(random_state=17)
X_resampled, T_resampled = smote_enn.fit_resample(X, T)

smote_tomek = SMOTETomek(random_state=5)
X_resampled, T_resampled = smote_tomek.fit_resample(X, T)

# https://imbalanced-learn.org/stable/combine.html

# sampling_strategy: ratio para problemas binarios. Diccionario con
# cantidades de muestras para problemas multiclase.
over = RandomOverSampler(sampling_strategy=0.5)
under = RandomUnderSampler(sampling_strategy=0.8)
X_over, T_over = over.fit_resample(X, T)
X_resampled, T_resampled = under.fit_resample(X_over, T_over)
```

Ponderación de clases

Algunas técnicas penalizan de manera diferente los errores cometidos durante el entrenamiento.

Los errores de las muestras de la clase minoritaria tienen más peso que las muestras de la otra clase.

- Hiperparámetro “class_weigth”.

Otras técnicas utilizan un desplazamiento del umbral de decisión. Aquellas que ofrecen un resultado probabilístico como respuesta, pueden desplazar el umbral a favor de la clase minoritaria.

Por ejemplo, al usar un umbral de 0.75, se establece que la respuesta a favor de la clase mayoritaria es tal, si la probabilidad es mayor a 0.75, caso contrario el algoritmo responde a favor de la clase minoritaria.

Ponderación de clases

```
from sklearn.ensemble import RandomForestClassifier

# Se debe definir en un diccionario, la ponderación de cada clase
cw = {0: 0.8, 1: 0.2}

rf1 = RandomForestClassifier(n_estimators = 100,
                             class_weight = cw)

rf2 = RandomForestClassifier(n_estimators = 100,
                             class_weight = "balanced")
                             # cada clase toma su peso de acuerdo a su
                             # proporción en el dataset

# Similar en otros modelos
```

Actividades

1. Utilice los diferentes métodos de under y over sampling vistos para mejorar la detección de la clase minoritaria en el dataset “glass”.

   Utilice un método de ensamble para la tarea de clasificación.

   Con el mismo ensamble entrene diferentes modelos usando para cada uno un dataset tratado con cada una de las técnicas de balance estudiadas.

   Realice la comparación de los resultados obtenidos de accuracy, precision y recall (estas últimas dos, de la clase minoritaria).